

מחילים:

אומר ג' - 318256120

יוסף פלג - 315717181


Introduction to Machine Learning

Exercise 1 – Answers

שאלה 1: בקובץ nearest_neighbour.py

שאלה 2:

a. פלט:

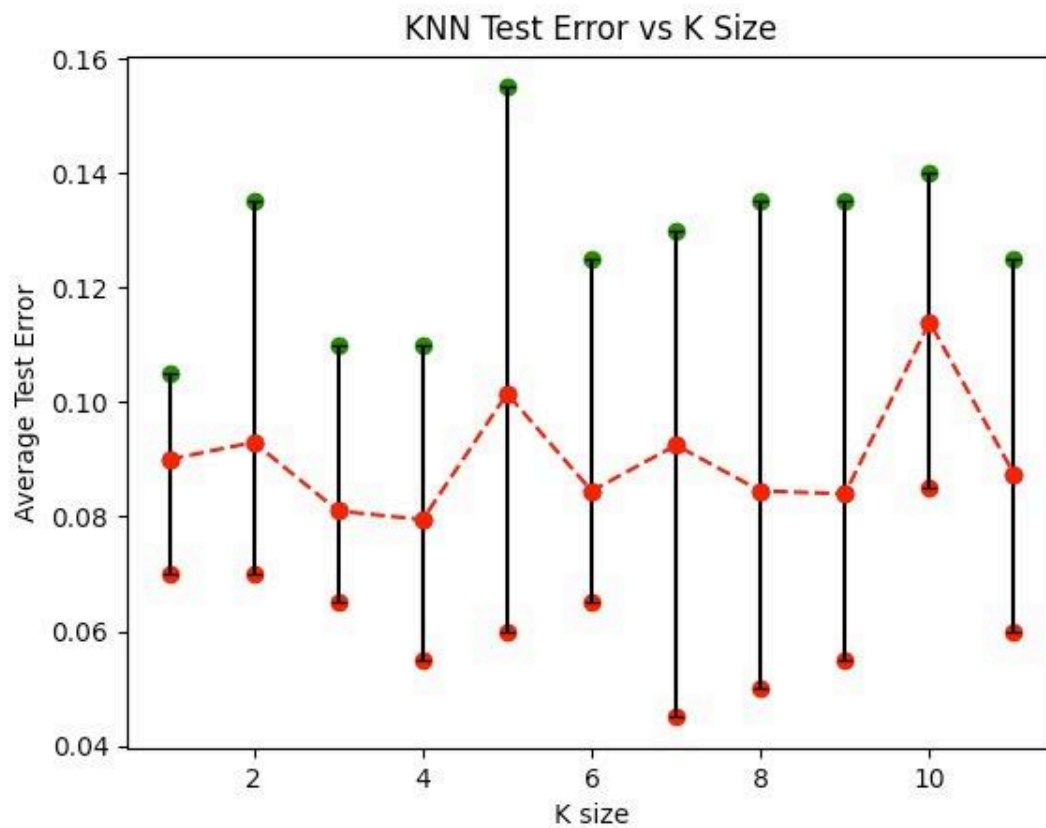


b. ניתן לראות בגרף המצורף שככל שאנו מגדילים את גודל המדגם, השגיאה הממוצעת קטנה. ניתן להסביר זאת מכמה סיבות.
ראשית, ככל שאנו מגדילים את גודל המדגם, ככה אנו יותר "דומים" להתפלגות האמיתית. כלומר, הסיכוי שנקבל מדגם שמחסיר סוגים שונים של לייבלים קטן.
שנית, מכיוון שאנו בודקים עבור test_data את המרחק מכל וקטור במדגם, הגדלת המדגם מגדילה את הסיכוי לקבל וקטור קרוב יותר עם תווית נכונה.

c. כן.

אנו עשויים לקבל תוצאות שונות עבור ריצות עם אותו גודל מדגם מכיוון שבכל ריצה בחירת המדגם מתבצעת באופן אקראי ולכן מדידת המרחקים של test_data עשויה להתבצע אל מול וקטורים שונים מהמדגם.

d. כן, הפרשי השגיאה (maxError - minError) קטנים ככל שגודל המדגם גדל.
בדומה לסעיף b, תופעה זו מעידה על כך שהמודל הופך ליותר יציב ועקבי כאשר הוא מאומן עם יותר דוגמאות. הגדלת המדגם מקרבת את ההתפלגות האמיתית בצורה טובה יותר, מה שמוביל לחיזוי אמין יותר ופחות משתנה.



כפי שניתן לראות בגרף, השגיאה המינימלית התקבלה כאשר $k=4$. במדגם בגודל 200 כאשר נרצה לבחון דוגמא חדשה בהסתברות גבוהה כבר פגשנו דוגמא קרובה לה בשלב האימון המסווגת נכון. עבור K קטן, המודל רגיש לרעש בנתונים, אשר עלול להוביל ל $over\ fitting$ (למידה על מס קטן של שכנים הקרובים ביותר). עבור K גדול, המודל עלול להוביל ל $under\ fitting$ מהסיבה שהמודל שוקל בחישוב יותר מידי שכנים, שחלקם עשויים להיות די רחוקים מהאינפוט וזה יכול לדלל את ההשפעה של השכנים הקרובים והרלוונטיים ביותר ולהוביל לעלייה בשגיאות. על כן, כדאי לבחור K מתאים בשביל לאזן את למידת המאפיינים אל מול רגישות יתר לרעש.

נתון $\mathcal{X} \times \mathcal{Y}$ מרחב מטרות, $\mathcal{Y} = \{0, 1\}$, D - $\mathcal{X} \times \mathcal{Y}$ מרחב מטרות, $\text{Bayes-error} = 0$ ו- D - $\mathcal{X} \times \mathcal{Y}$ מרחב מטרות.

כאשר $x, y \in \mathcal{X} \times \mathcal{Y}$ ו- $\eta_y(x) \in \{0, 1\}$.

$|\eta(x_1) - \eta(x_2)| \leq C \cdot \rho(x_1, x_2)$, $x_1, x_2 \in \text{Supp}(0)$ ו- C -Lipschitz.

(a) $\mathcal{S} \sim D^m$, $(x_1, y_1), (x_2, y_2) \in \mathcal{S}$ ו- $y_1 \neq y_2$.

$x_1, x_2 \in \text{Supp}(0)$ ו- $(x_1, y_1), (x_2, y_2) \in \mathcal{S}$.

$\mathcal{Y} = \{0, 1\}$
 $y_1 \neq y_2$
מרחב מטרות D

$$|\eta(x_1) - \eta(x_2)| = 1 \leq C \cdot \rho(x_1, x_2) \Leftrightarrow \frac{1}{C} \leq \rho(x_1, x_2) \stackrel{\text{דistanse}}{=} \|x_1 - x_2\|$$

המרחק $\frac{1}{C} \leq \|x_1 - x_2\|$.

(b) $f_S^m(x) \neq y$ ו- $(x, y) \in \mathcal{S}$ קיים $\text{err}(f_S^m, D) \neq 0$.

$x \in \mathcal{X}$ ו- $x \in \mathcal{B}$ ו- $\mathcal{B}^* \subseteq \mathcal{B}$ ו- $x \in \mathcal{B}$ ו- $\mathcal{B}^* \subseteq \mathcal{B}$.

נתון $x \in \mathcal{X}$ ו- $x \in \mathcal{B}$ ו- $\mathcal{B}^* \subseteq \mathcal{B}$ ו- $x \in \mathcal{B}$ ו- $\mathcal{B}^* \subseteq \mathcal{B}$.

קיים $x' \in \mathcal{B}^*$ ו- $\rho(x, x') \leq \frac{2}{3C}$ (כאשר $\frac{2}{3C}$ הוא קוטר \mathcal{B}^*).

נניח $\frac{2}{3C} \leq \frac{1}{C}$ ו- $\rho(x', x) \geq \frac{1}{C}$, (a) ו- $\frac{2}{3C} \leq \frac{1}{C}$.

$$X = \{(x_1, x_2) \mid x_1 \in [0, 42], x_2 \in [0, 5]\} \quad , \quad Y \in \{\text{black}, \text{white}\} \quad (a)$$

$$h_{\text{bayes}}(8, 4) = \text{black} \quad \Leftarrow \quad \eta_w(8, 4) = 0.06 \quad \eta_b(8, 4) = 0.42 \quad (b)$$

$$h_{\text{bayes}}(15, 1) = \text{black} \quad \Leftarrow \quad \eta_w(15, 1) = 0.07 \quad \eta_b(15, 1) = 0.21$$

$$h_{\text{bayes}}(15, 2) = \text{white} \quad \Leftarrow \quad \eta_w(15, 2) = 0.24$$

$$\text{error}(h, D) = \sum_{x \in X} P(X=x) (1 - \eta_{h_{\text{bayes}}(x)}(x)) \quad \text{כ} \quad (c)$$

$$\begin{aligned} \text{error}(h, D) &= P_r(8, 4) \cdot (1 - \eta_{h_{\text{bayes}}(8, 4)}(8, 4)) + P_r(15, 1) \cdot (1 - \eta_{h_{\text{bayes}}(15, 1)}(15, 1)) + P_r(15, 2) \cdot (1 - \eta_{h_{\text{bayes}}(15, 2)}(15, 2)) \\ &\stackrel{(b)}{=} P_r(8, 4) \cdot (1 - \eta_{\text{black}}(8, 4)) + P_r(15, 1) \cdot (1 - \eta_{\text{black}}(15, 1)) + P_r(15, 2) \cdot (1 - \eta_{\text{white}}(15, 2)) \\ \eta_y(x) &= \frac{P_r(Y=y, X=x)}{P_r(X=x)} = 0.48 \cdot (1 - \frac{0.42}{0.48}) + 0.28 \cdot (1 - \frac{0.21}{0.28}) + 0.24 \cdot (1 - \frac{0.24}{0.24}) = 0.13 \quad \leftarrow \text{כ} \end{aligned}$$

$$\text{Approximation error : } \text{err}_{\text{app}} := \min_{h \in \mathcal{H}} \text{err}(h, D).$$

(d) נשים את η של h תלוי את h ונרצה למצוא את η :

$$h_b(x) = \text{black} \quad , \quad h_w(x) = \text{white} \quad \mathcal{H} = \{h_1, h_2\}$$

נחשב את הטעות של h_1, h_2 ונבחר את הטעות הקטנה ביותר.

$$\begin{aligned} \text{err}(h_b, D) &= \sum_{x \in X} P(X=x) (1 - \eta_{h_b(x)}(x)) = \\ &= P_r(8, 4) \cdot (1 - \eta_{h_b(8, 4)}(8, 4)) + P_r(15, 1) \cdot (1 - \eta_{h_b(15, 1)}(15, 1)) + P_r(15, 2) \cdot (1 - \eta_{h_b(15, 2)}(15, 2)) \\ &= P_r(8, 4) \cdot (1 - \eta_{\text{black}}(8, 4)) + P_r(15, 1) \cdot (1 - \eta_{\text{black}}(15, 1)) + P_r(15, 2) \cdot (1 - \eta_{\text{black}}(15, 2)) \\ &= 0.48 \cdot (1 - \frac{0.42}{0.48}) + 0.28 \cdot (1 - \frac{0.21}{0.28}) + 0.24 \cdot (1 - 0) = 0.13 + 0.24 = 0.37 \end{aligned}$$

$$\begin{aligned} \text{err}(h_w, D) &= \sum_{x \in X} P(X=x) (1 - \eta_{h_w(x)}(x)) = \\ &= P_r(8, 4) \cdot (1 - \eta_{h_w(8, 4)}(8, 4)) + P_r(15, 1) \cdot (1 - \eta_{h_w(15, 1)}(15, 1)) + P_r(15, 2) \cdot (1 - \eta_{h_w(15, 2)}(15, 2)) \\ &= P_r(8, 4) \cdot (1 - \eta_{\text{white}}(8, 4)) + P_r(15, 1) \cdot (1 - \eta_{\text{white}}(15, 1)) + P_r(15, 2) \cdot (1 - \eta_{\text{white}}(15, 2)) \\ &= 0.48 \cdot (1 - \frac{0.06}{0.48}) + 0.28 \cdot (1 - \frac{0.07}{0.28}) + 0.24 \cdot (1 - \frac{0.24}{0.24}) = 0.63 \end{aligned}$$

$$\text{err}(h_b, D) = 0.37 \quad \text{כ} \quad \text{שליש הקטנה ביותר}$$

$$\mathbb{E}_{S \sim \mathcal{D}^m}[\text{err}(\hat{h}_S, \mathcal{D})] = \frac{k-1}{k} \sum_{x \in \mathcal{X}} p_x (1 - p_x)^m.$$

(e)


תנאים: $m=3$, $k=2$ (black, white)

$$\begin{aligned} E[\text{err}(h, 0'')] &= \frac{1}{2} \cdot \sum_{x \in \mathcal{X}} p_x (1 - p_x)^m \\ &= \frac{1}{2} \cdot [p_{(g, w)} (1 - p_{(g, w)})^3 + p_{(g, s)} (1 - p_{(g, s)})^3 + p_{(g, b)} (1 - p_{(g, b)})^3 + p_{(w, b)} (1 - p_{(w, b)})^3] = \\ &= \frac{1}{2} \cdot [0.08 (1 - 0.08)^3 + 0.15 (1 - 0.15)^3 + 0.47 (1 - 0.47)^3 + 0.3 (1 - 0.3)^3] = \underline{\underline{0.163}} \end{aligned}$$

נשים אם כי זהירות "ס" יש תווית דטרמיניסטית (בסוף מהתפלגות 0) וכן הסתברות לאטם תלויה
ה- M_S שלדכן הכיתה (missing mass - ההסתברות שנקודה x לא נצפה באימון).

ההסתברות לא דטרמיניסטית 0, האלף Memorize לא יכול למצוא בזיכרון את התוצאות של הדוגמאות
היון צפה (יתכן כמה תוויות עבור דוגמאות בודדות), אם כן, שימוש בנוסחה של תוחלת השגיאה של אלף ה-Memorize
לא ניתר אשמוש בזיכרון אשר נלמדה מכיתה.

$$S = \{(0.5, 5.5), (2.7, 4.5), (4.5, 2.5), (-1.5, 1.2), (-5.5, 0.5), (-1.9, -1.5), (-3.5, -3.2), (-1.3, -4.5), (3.3, -1.6), (1.5, -4.5), (3.5, 7), (5.5, 5.5), (6.9, 5.6), (-7.1, 6.5), (-4.5, 5.5), (-7.2, 1.5), (-6.5, -1.5), (-5.5, 4.2), (5.3, -4.5), (4.5, -5.5)\}$$




(a) לפי הנתונים, הסף הניתני. T_h, T_v יהיה 5.5.

$$H_{rec} := \{f_{T_h, T_v}^{rec} \mid T_h = T_v = 5.5\}$$

עם אגף ERM נמצא את המלבן המורכב מהצורה $x_v = 5.5, x_h = 5.5$

$$\hat{err}(h, s) = \frac{1}{20} \cdot \sum_{i=1}^{20} \mathbb{I}[h(x_i) \neq y_i] = \frac{1}{20} \cdot 5 = \frac{1}{4}$$

ב הנק' האדומה
ממחיש פסגה של 1/4



(b) נגזר את g כדור משואה מוצא: $g(x_h, x_v) = \sqrt{x_h^2 + x_v^2}$

$$H_g := \{f_{g, T} \mid T \in [5.5, 6.5]\}$$

• ניתן לבדוק כי עבור $T \in [5.5, 6.5]$, H_g יתפזר לנו שגור אמפירית השווה ל-0.

הנתן המלבן הנוכחי.

• ניתן להניח כי H_g תספק בריבועי הסדרה ERM של יתרי ממשו H_{rec} לאחר

וקבידת הסף ע' רדיוס המלבן מתאימה יותר לנתנת החקלאי אשר בודק את מרחק הנתונים

מינצו העץ, עכן כאשר נקרא תפוח חדש שאין במצבם נרצה לתפוח את סיווגו בהתאם למרחק שלו ממשו העץ ולא תלת הצורה המבוסס.

